# Laporan Analisis Final Project Kecerdasan Artifisial dan Machine Learning

# Anggota Kelompok:

- Wisnu Adjie Saka | 5027211051
- Adimasdefatra | 5027211040

### Exploratory Data Analysis (EDA)

Setelah melakukan load dataset dari soal yang diberikan, kita melakukan eksplorasi data dengan melakukan "data.head()" pada ketiga data yang diberikan untuk melihat isi dari data tersebut, lalu melakukan cek missing value dan value count pada data "re\_dataset". Selanjutnya pada visualisasi, kita menunjukkan count plot, distribusi label dari semua label pada data "re\_dataset", lalu juga visual dari kata "abusive" yang paling banyak dipakai pada data tersebut ( Lebih jelas nya bisa lihat pada notebook ).

## Pre-Processing

Setelah melakukan eksplorasi data, selanjutnya kita melakukan tahap "pre processing". Pada tahap ini pertama kita melakukan normalisasi "Alay dan Slang Words" berdasarkan file "new\_kamusalay.csv", melakukan lowercasing, menghapus karakter yang tidak dibutuhkan seperti '\n', 'rt', 'user', dan URL, menghapus karakter "Non-Alphanumeric", menghapus stopwords, selanjutnya melakukan proses stemming mengubah kata-kata dalam teks menjadi bentuk dasarnya. Setelah melalui proses pre processing, dataset telah dirapikan dan selanjutnya masuk ke bagian pembangunan model.

#### Build Model dan Evaluasi Model

Setelah melakukan pre-processing pada data, selanjutnya kita melakukan tahap pembangunan model dan evaluasi model. kita membangun model ini menggunakan algoritma Logistic Regression dengan menerapkan TfidfVectorizer pada data Tweet. kita memilih algoritma ini karena mampu mengatasi masalah klasifikasi teks dengan baik dan memiliki kemampuan untuk menangani fitur-fitur yang besar. Pemilihan TfidfVectorizer membantu mengukur frekuensi relatif kata-kata dalam teks, memberikan bobot yang lebih tinggi pada kata-kata yang lebih informatif. Proses pelatihan model dilakukan menggunakan dataset yang telah melalui tahap pre-processing sebelumnya. Model-model untuk setiap label (kategori) disimpan dalam sebuah dictionary untuk penggunaan dan evaluasi selanjutnya. Setelah model klasifikasi siap digunakan, kita melakukan evaluasi untuk setiap label. Evaluasi dilakukan menggunakan akurasi, precision, recall, dan F1-score. Hasil evaluasi ini (Bisa dilihat di notebook) menunjukan kinerja model dalam memprediksi setiap kategori, yang berguna untuk memahami lebih lanjut terkait efektivitas model pada tugas deteksi "hate speech dan abusive language". Dan setelah melakukan evaluasi model menggunakan berbagai matriks yang diberikan, selanjutnya akan melakukan prediksi berdasarkan model yang telah kita bangun ini.

### Hasil Prediksi Menggunakan Model

Setelah melakukan pembuatan dan evaluasi model, terakhir kita akan melakukan prediksi input contoh tweet menggunakan model kita. Disini kita menggunakan dua input, input 1: "Goblok, dasar SAKA tolol, jadi orang tu jangan idiot lah, anjing" dan input 2: "'Kamu keren Saka, kerja bagus". Untuk input 2 itu merupakan kata-kata baik dan tidak mengandung HS sama sekali jadi pada deteksi mengatakan input 2 bukan HS, sebaliknya hasil prediksi dari input 1 mengatakan bahwa, input 1 mengandung HS, Abusive, HS\_Individual, HS\_Other, dan HS\_Weak ( Lebih lengkap nya bisa lihat pada notebook ). Jadi kita berhasil melakukan deteksi apakah tweet yang kita input merupakan HS atau bukan dari model yang kita buat .